

Defesa de Dissertação

Utilização de redes neurais artificiais para detecção e diagnóstico de falhas

Diogo Leite Rebouças
diogolr@dca.ufrn.br

Universidade Federal do Rio Grande do Norte
Programa de Pós-Graduação em Engenharia Elétrica e de Computação

21 de junho de 2011



1 Introdução

- Introdução da automação na indústria
- Sistemas de supervisão
- Proposta do trabalho

2 RNAs

- Características
- Arquitetura e modelo neural

3 Detecção e diagnóstico de falhas

- Conceitos e terminologias
- Dependabilidade
- Falhas, erros e avarias
- Classificações de falhas
- Detecção e diagnóstico

4 Sistema proposto

- Estudo de caso
- Estrutura de funcionamento e limitações
- Softwares desenvolvidos
- Composição do sistema
- Estruturas neurais

5 Resultados

- Coleta dos dados
- Treinamento e validação das RNAs
- Melhores redes
- Resultados das simulações

6 Conclusões

- Perspectivas

7 Vídeo



1 Introdução

Introdução da automação na indústria
Sistemas de supervisão
Proposta do trabalho

2 RNAs

Características
Arquitetura e modelo neural

3 Detecção e diagnóstico de falhas

Conceitos e terminologias
Dependabilidade
Falhas, erros e avarias
Classificações de falhas
Detecção e diagnóstico

4 Sistema proposto

Estudo de caso
Estrutura de funcionamento e limitações
Softwares desenvolvidos
Composição do sistema
Estruturas neurais

5 Resultados

Coleta dos dados
Treinamento e validação das RNAs
Melhores redes
Resultados das simulações

6 Conclusões

Perspectivas

7 Vídeo

Introdução da automação na indústria



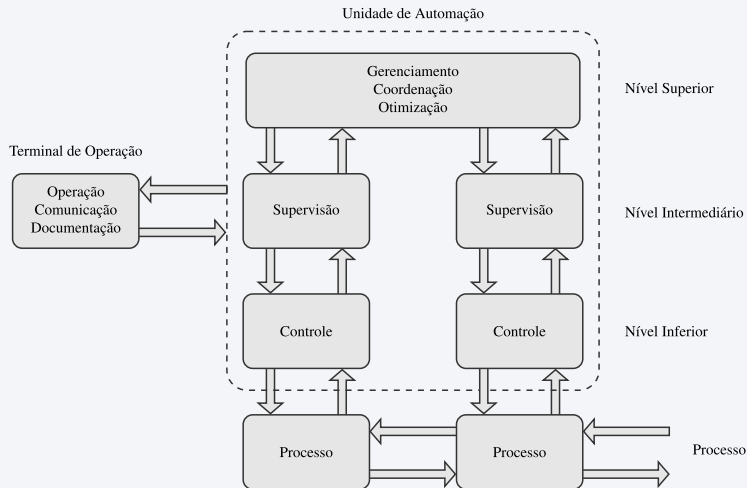
Com o surgimento dos CLPs e a popularização do controle automático, foco da indústria:

- Desempenho dos processos
- Qualidade dos produtos
- Independência de funcionamento da planta para com os operadores humanos

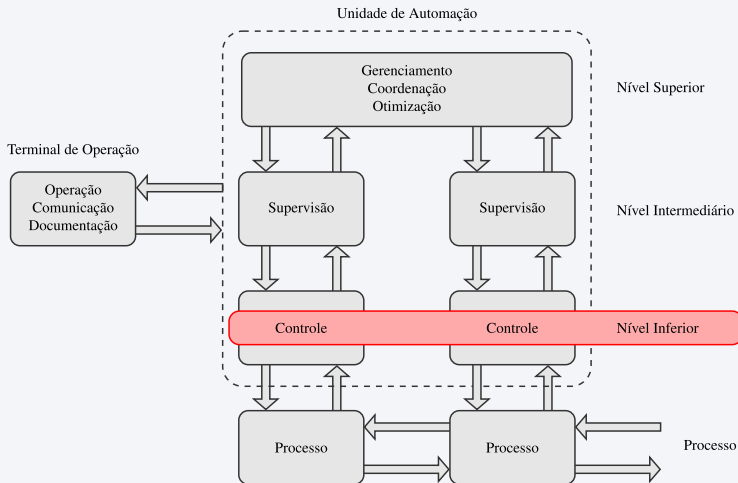
Evolução \Rightarrow processos divididos em várias camadas de finalidades específicas:

- Controle (Inferior)
- Supervisão (Intermediário)
- Logística/Gerenciamento (Superior)

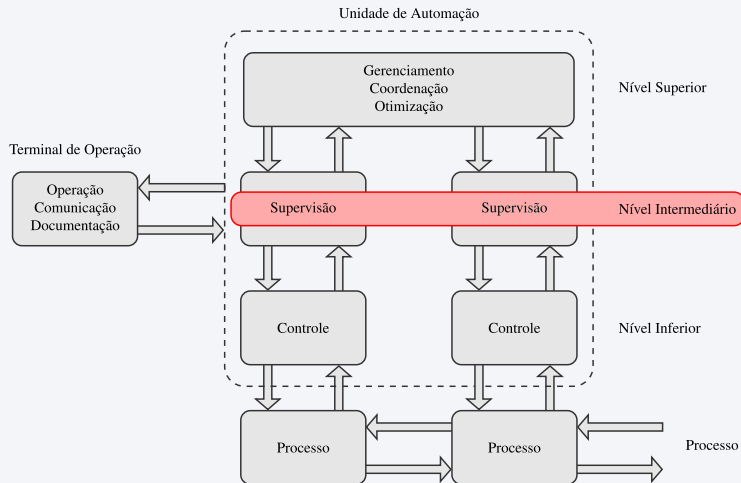
Introdução da automação na indústria



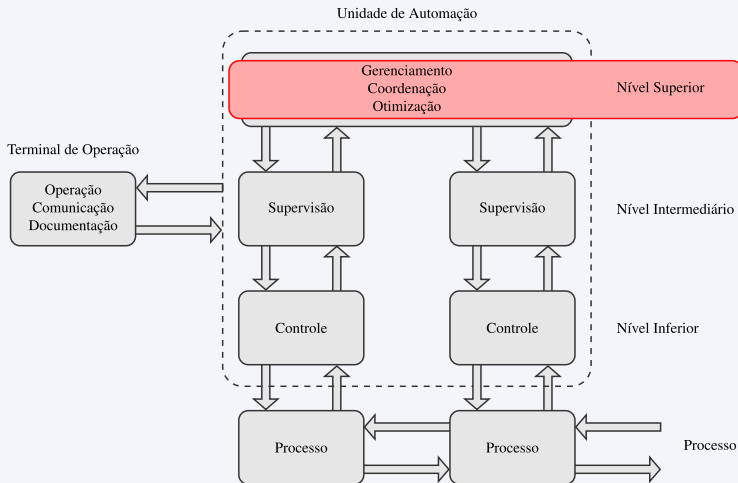
Introdução da automação na indústria



Introdução da automação na indústria



Introdução da automação na indústria



Introdução da automação na indústria



Aumento da eficiência das estratégias de controle (nível inferior):

- Operadores são retirados do processo

Contudo:

- Operadores não se limitam a controlar o processo e mudar referências
- Realizam atividade de supervisão (contato direto)

Maior eficiência (nível inferior) \Rightarrow Melhoramento das estratégias de supervisão (nível intermediário)

Sistemas de supervisão



Surgimento dos primeiros sistemas de supervisão:

- Verificavam limites de determinadas variáveis
- Se o limite fosse ultrapassado \Rightarrow alarme para o operador
- Operador agia de maneira rápida para corrigir o problema

Em alguns casos \Rightarrow correção do problema de maneira automática

Entretanto as falhas/erros só eram detectados após um certo intervalo

- Impossibilidade de gerar um diagnóstico detalhado sobre o ocorrido

Sistemas de supervisão



Novas estratégias passaram a ser desenvolvidas (diversas técnicas):

- Modelos matemáticos
- Modelos de sinais
- Métodos de identificação/estimação
- **Técnicas de IA**

Objetivo dessas estratégias:

- Desenvolver um sistema capaz de detectar e diagnosticar falhas em um processo de maneira rápida e eficiente

Proposta do trabalho



Sistema proposto:

- Baseado em Técnicas de IA (RNAs)
- Constituído por estruturas neurais simples ou compostas

Objetivos do sistema:

- Detectar e diagnosticar falhas em um processo
- Gerar sinais que possam ser pós-processados (notificação, geração de alarmes)
- Estudo de caso: Sistema de tanques acoplados



1 Introdução

Introdução da automação na indústria
Sistemas de supervisão
Proposta do trabalho

2 RNAs

Características
Arquitetura e modelo neural

3 Detecção e diagnóstico de falhas

Conceitos e terminologias
Dependabilidade
Falhas, erros e avarias
Classificações de falhas
Detecção e diagnóstico

4 Sistema proposto

Estudo de caso
Estrutura de funcionamento e limitações
Softwares desenvolvidos
Composição do sistema
Estruturas neurais

5 Resultados

Coleta dos dados
Treinamento e validação das RNAs
Melhores redes
Resultados das simulações

6 Conclusões

Perspectivas

7 Vídeo

Características



Opção por RNAs:

- Capacidade de generalização
- Adaptabilidade
- Incorporação das não-linearidades do processo

RNAs utilizadas para:

- Detecção
- Diagnóstico
- Identificação do modelo

Arquitetura e modelo neural




Arquitetura: Rede PMC, completamente conectada

Treinamento: Levenberg-Marquardt (LMA) – Matlab[®]

- Método Quase-Newton
- Rápida convergência

Modelo Neural: NNARX



Critério de parada: EMQ



1 Introdução

- Introdução da automação na indústria
- Sistemas de supervisão
- Proposta do trabalho

2 RNAs

- Características
- Arquitetura e modelo neural

3 Detecção e diagnóstico de falhas

- Conceitos e terminologias
- Dependabilidade
- Falhas, erros e avarias
- Classificações de falhas
- Detecção e diagnóstico

4 Sistema proposto

- Estudo de caso
- Estrutura de funcionamento e limitações
- Softwares desenvolvidos
- Composição do sistema
- Estruturas neurais

5 Resultados

- Coleta dos dados
- Treinamento e validação das RNAs
- Melhores redes
- Resultados das simulações

6 Conclusões

- Perspectivas

7 Vídeo

Conceitos e terminologias



Necessidades de otimização dos processos (qualidade, tempo de produção, custo):

- Evidenciaram a importância dos sistemas de **Detecção e Diagnóstico de Falhas** (DDFs)

Dentre os diversos conceitos envolvidos nos sistemas de DDF:

- Falha
- Erro
- Avaria
- Dependabilidade

Existem muitas divergências relacionadas a definição desses termos

Dependabilidade



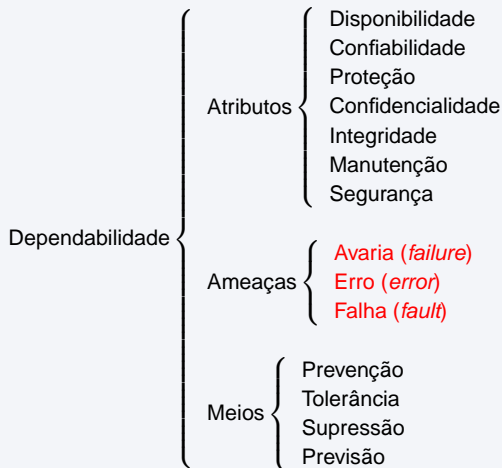
Sistemas computacionais podem ser caracterizados:

- Funcionalidade
- Usabilidade
- Desempenho
- Custo
- **Dependabilidade** (tradução literal de *dependability*)

Definição

Dependabilidade: *Capacidade de um sistema prestar um serviço que possa ser, justificadamente, confiável.*

Dependabilidade



Falhas, erros e avarias



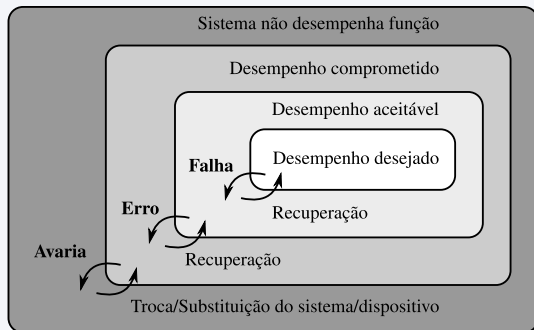
Falhas, erros e avarias são conceitos que não devem ser confundidos

- **Avaria (*failure*):** utilizado para indicar que houve um desvio do comportamento do sistema, o que o torna incapaz de fornecer o serviço para o qual foi designado
- **Erro (*error*):** é relacionado com o estado do sistema e **pode** levar a uma avaria (sequência de passos)
- **Falha (*fault*):** é dita a causa dos erros, ou seja, está associada à noção de defeitos

Falhas, erros e avarias



Mapa de conceitos:



... \Rightarrow Falha \rightarrow Erro \rightarrow Avaria \Rightarrow Falha \rightarrow ...


Classificações de falhas



Falhas podem ser classificadas sobre diversos aspectos

Classificação quanto ao tempo:

- Abrupta
- Incipiente
- Intermitente



Classificação de falhas



Podem agir em diversas partes do sistema

Exemplos de falhas (sistema genérico):

Sensores	Atuadores	Estrutura
Erro de leitura	Erro de escrita	Erro de transmissão
Descalibramento	Erro de leitura	Perda de comunicação
Sensibilidade à ruído	Sensibilidade à ruído	Sensibilidade a ruído (transmissor)
Queima	Queima	Queima (transmissor)
-	Atraso de transporte	Atraso de propagação de sinais


Detecção e diagnóstico



Objetivos de um sistema de DDF:

- Detectar e Diagnosticar falhas
- Sugerir medidas corretivas ao operador \Rightarrow Garantir continuidade da operação do processo

Na realidade, DDF subdividido em 4 etapas:



Detecção e diagnóstico



O sistema proposto neste trabalho abrange as 3 primeiras etapas:

- **Detectar:** determinar se ocorreu ou não uma falha
- **Identificar:** seleccionar variáveis importantes para o diagnóstico
- **Diagnosticar:** definir que falha ocorreu e fornecer o maior número de detalhes possíveis
 - Localização
 - Momento de detecção
 - Intensidade
 - ...

Detecção e diagnóstico



Existem diversas técnicas para detecção e diagnóstico

- Detecção:
 - Verificação de limites
 - Equações de paridade
 - Observadores/Estimadores de estado
- Diagnóstico:
 - Classificação estatística
 - Reconhecimento de padrões
 - Métodos de aproximação

Dentre as várias técnicas \Rightarrow RNAs (detecção e diagnóstico)



1 Introdução

Introdução da automação na indústria
Sistemas de supervisão
Proposta do trabalho

2 RNAs

Características
Arquitetura e modelo neural

3 Detecção e diagnóstico de falhas

Conceitos e terminologias
Dependabilidade
Falhas, erros e avarias
Classificações de falhas
Detecção e diagnóstico

4 Sistema proposto

Estudo de caso
Estrutura de funcionamento e limitações
Softwares desenvolvidos
Composição do sistema
Estruturas neurais

5 Resultados

Coleta dos dados
Treinamento e validação das RNAs
Melhores redes
Resultados das simulações

6 Conclusões


Perspectivas

7 Vídeo

Estudo de caso



Sistemas de tanques acoplados da Quanser®



Estudo de caso



Sistema original:

- Estrutura em acrílico
- Dois tanques
- Dois sensores de pressão
- Uma bomba de sucção bidirecional
- Mangueiras
- Orifícios (Entrada/Saída)

Manual do fabricante \Rightarrow Sugere três configurações

- Controlar L_1 (alimentação direta em T_1)
- Controlar L_2 (alimentação indireta em T_1)
- Controlar L_2 (alimentação em T_1 e T_2)

Todas as três configurações \Rightarrow Sistema SISO

Estudo de caso



Modelo matemático (EDOs não-lineares):

$$\begin{aligned}\dot{L}_1 &= \frac{K_m}{A} V_p - \left[\frac{a_1}{A} \sqrt{2g} \right] \sqrt{L_1} \\ \dot{L}_2 &= \left[\frac{a_1}{A} \sqrt{2g} \right] \sqrt{L_1} - \left[\frac{a_2}{A} \sqrt{2g} \right] \sqrt{L_2}\end{aligned}$$

Modificações do modelo:

- Introdução de uma nova bomba
- Possibilidade de controlar L_1 e L_2 simultaneamente
- Sistema SISO \Rightarrow Sistema MIMO

Estudo de caso



Modelo matemático (EDOs não-lineares):

$$\begin{aligned}\dot{L}_1 &= \frac{K_m}{A} V_p - \left[\frac{a_1}{A} \sqrt{2g} \right] \sqrt{L_1} \\ \dot{L}_2 &= \left[\frac{a_1}{A} \sqrt{2g} \right] \sqrt{L_1} - \left[\frac{a_2}{A} \sqrt{2g} \right] \sqrt{L_2}\end{aligned}$$

Modificações do modelo:

- Introdução de uma nova bomba
- Possibilidade de controlar L_1 e L_2 simultaneamente
- Sistema SISO \Rightarrow Sistema MIMO

Estudo de caso



Modelo matemático (EDOs não-lineares):

$$\begin{aligned}\dot{L}_1 &= \frac{K_m}{A} V_p - \left[\frac{a_1}{A} \sqrt{2g} \right] \sqrt{L_1} \\ \dot{L}_2 &= \left[\frac{a_1}{A} \sqrt{2g} \right] \sqrt{L_1} - \left[\frac{a_2}{A} \sqrt{2g} \right] \sqrt{L_2}\end{aligned}$$

Modificações do modelo:

- Introdução de uma nova bomba
- Possibilidade de controlar L_1 e L_2 simultaneamente
- Sistema SISO \Rightarrow Sistema MIMO

Estudo de caso



Modelo matemático (EDOs não-lineares):

$$\begin{aligned}\dot{L}_1 &= \frac{K_m}{A} V_p - \left[\frac{a_1}{A} \sqrt{2g} \right] \sqrt{L_1} \\ \dot{L}_2 &= \left[\frac{a_1}{A} \sqrt{2g} \right] \sqrt{L_1} - \left[\frac{a_2}{A} \sqrt{2g} \right] \sqrt{L_2}\end{aligned}$$

Modificações do modelo:

- Introdução de uma nova bomba
- Possibilidade de controlar L_1 e L_2 simultaneamente
- Sistema SISO \Rightarrow Sistema MIMO

Estudo de caso



Modelo matemático (EDOs não-lineares):

$$\begin{aligned}\dot{L}_1 &= \frac{K_m}{A} V_p - \left[\frac{a_1}{A} \sqrt{2g} \right] \sqrt{L_1} \\ \dot{L}_2 &= \left[\frac{a_1}{A} \sqrt{2g} \right] \sqrt{L_1} - \left[\frac{a_2}{A} \sqrt{2g} \right] \sqrt{L_2}\end{aligned}$$

Modificações do modelo:

- Introdução de uma nova bomba
- Possibilidade de controlar L_1 e L_2 simultaneamente
- Sistema SISO \Rightarrow Sistema MIMO

Estudo de caso



Modelo matemático (EDOs não-lineares):

$$\begin{aligned}\dot{L}_1 &= \frac{K_m}{A} V_p - \left[\frac{a_1}{A} \sqrt{2g} \right] \sqrt{L_1} \\ \dot{L}_2 &= \left[\frac{a_1}{A} \sqrt{2g} \right] \sqrt{L_1} - \left[\frac{a_2}{A} \sqrt{2g} \right] \sqrt{L_2}\end{aligned}$$

Modificações do modelo:

- Introdução de uma nova bomba
- Possibilidade de controlar L_1 e L_2 simultaneamente
- Sistema SISO \Rightarrow Sistema MIMO

Estudo de caso



Modelo matemático (EDOs não-lineares):

$$\begin{aligned}\dot{L}_1 &= \frac{K_m}{A} V_{p1} - \left[\frac{a_1}{A} \sqrt{2g} \right] \sqrt{L_1} \\ \dot{L}_2 &= \left[\frac{a_1}{A} \sqrt{2g} \right] \sqrt{L_1} - \left[\frac{a_2}{A} \sqrt{2g} \right] \sqrt{L_2} + \frac{K_m}{A} V_{p2}\end{aligned}$$

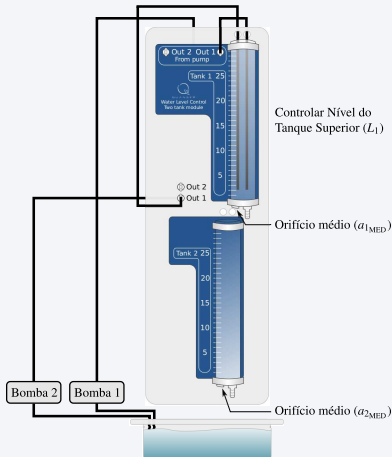
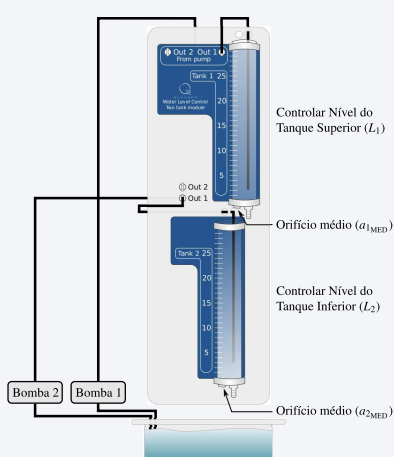
Modificações do modelo:

- Introdução de uma nova bomba
- Possibilidade de controlar L_1 e L_2 simultaneamente
- Sistema SISO \Rightarrow Sistema MIMO

Estudo de caso



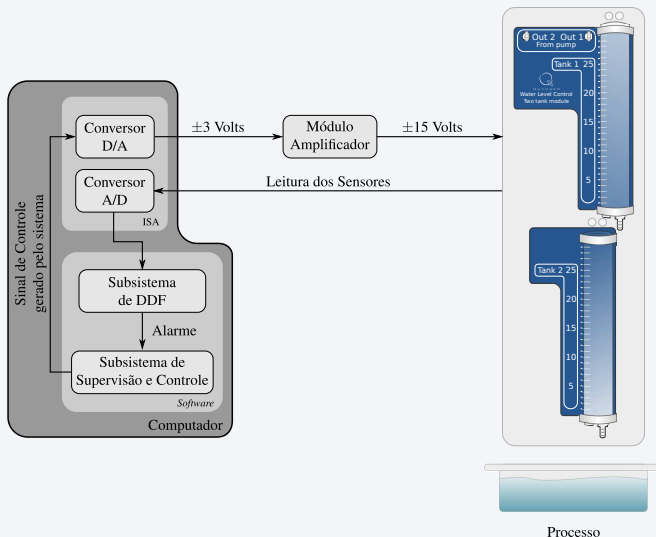
Novas configurações:



Estrutura de funcionamento e limitações



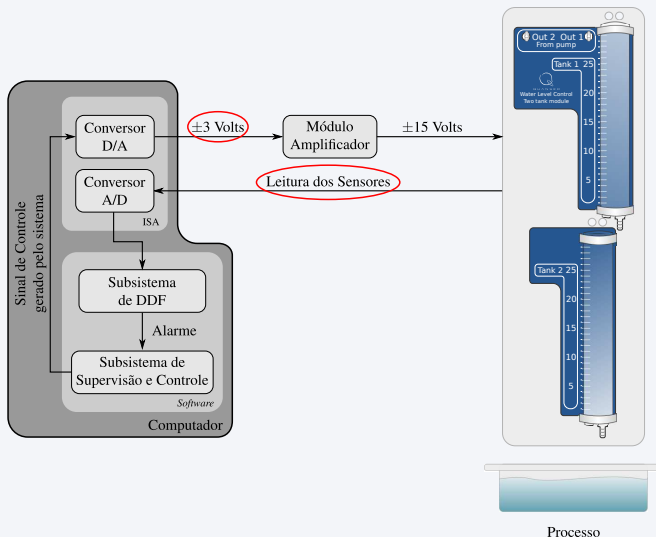
Estrutura de funcionamento:



Estrutura de funcionamento e limitações



Estrutura de funcionamento:



Simulações



Necessidade da simulação do modelo \Rightarrow Incitar falhas na planta real = Prejuízos

EDOs do modelo simuladas com Runge-Kutta 4^a ordem

Falhas simuladas através de modificações dos parâmetros na simulação

Grupos de falhas selecionadas:

Grupo	Tipo de falha	Sigla
0	Não há falhas	SF
1	Falha do sensor	FSe
2	Falha do atuador	FA
3	Falha estrutural ou Falha do sistema	FSi



Classificação das falhas:

Grupo	Classe	Denominação	Variante	Sigla
1	1	Descalibramento	Ganho	FSeDG
1	1	Descalibramento	Nível DC (<i>offset</i>)	FSeDO
1	2	Sensibilidade	Ruído	FSeSR
1	3	Queima	–	FSeQ
2	1	Descalibramento	Ganho	FADG
2	1	Descalibramento	Nível DC (<i>offset</i>)	FADO
2	2	Sensibilidade	Ruído	FASR
2	3	Variação	Constante da bomba (K_m)	FAVK
2	4	Queima	–	FAQ
3	3	Vazamento	Tanque	FSiVzT
3	2	Variação	Orifício de saída	FSiVrOS
3	2	Variação	Ganho do módulo de potência	FSiVrGMP
3	1	Entupimento	Orifício de saída	FSiEOS



Sistema desenvolvido para as simulações (Qt/C++)

- Configuração através de arquivo de texto simples
- Simulação em tempo real ou Simulação rápida
- Implementação de controladores P/PI/PD/PID/PI-D
- Comunicação com a planta real (Sockets TCP/IP)
- Exportação de dados (Sinais de controle, ações de controle e saídas dos sensores)
- Exportação de imagens (Diversos formatos)

Detecção e diagnóstico



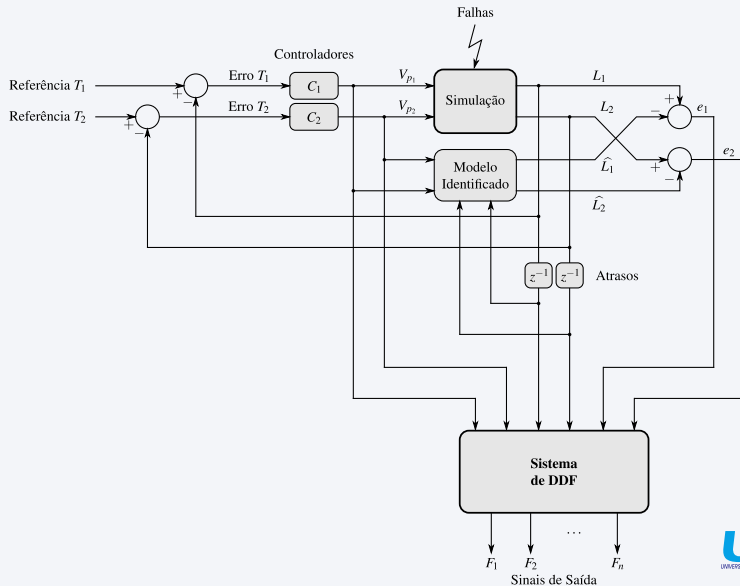
Sistema desenvolvido para a detecção e o diagnóstico (Qt/C++)

- Configuração através de arquivos XML
- Diferentes módulos detecção/diagnóstico (RNAs, estatísticos, Fuzzy ...)
- Módulos desenvolvidos sobre interface padronizada (Classe abstrata)
- Cadastramento/Edição/Remoção de falhas
- Exportação de imagens (Diversos formatos)

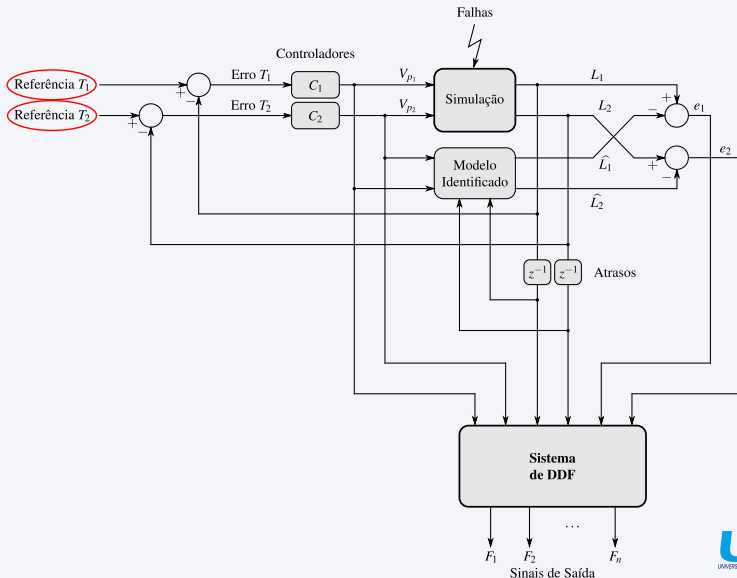
Módulo de RNAs:

- Desenvolvido em C++ (Biblioteca Flood)
- Permite que as redes treinadas pelo Matlab[®] sejam carregadas de maneira simples

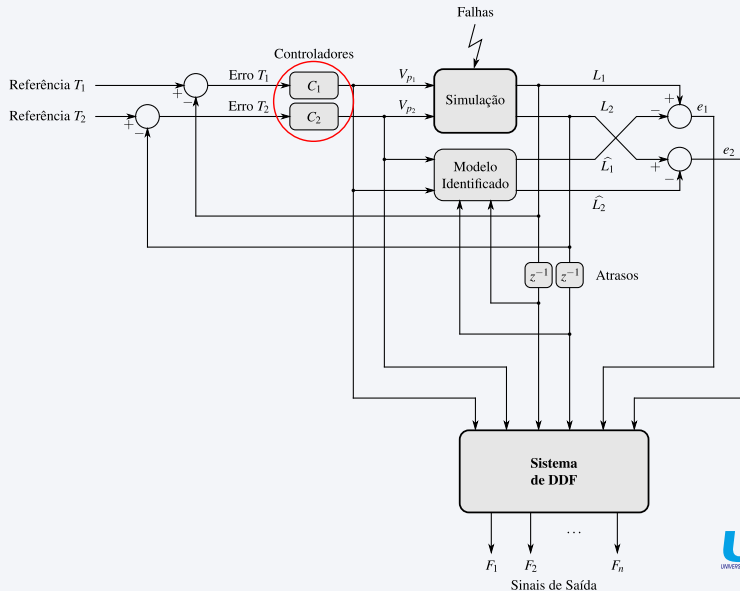
Composição do sistema



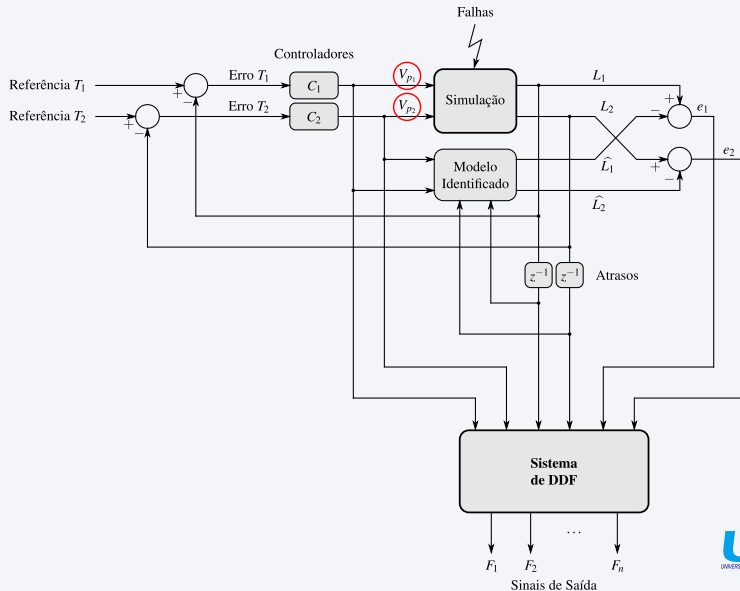
Composição do sistema



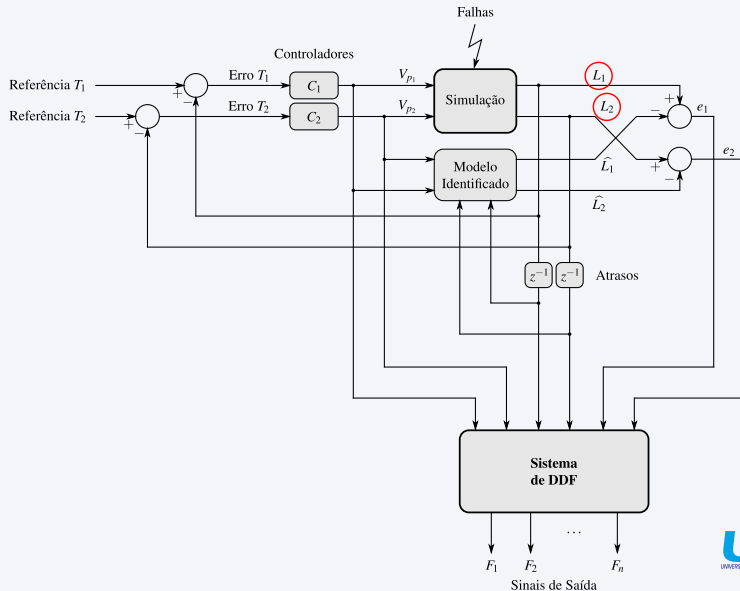
Composição do sistema



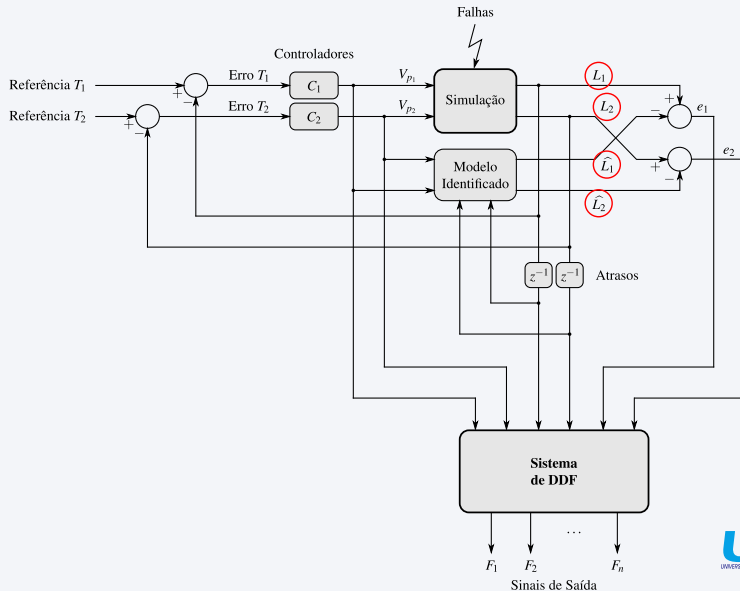
Composição do sistema



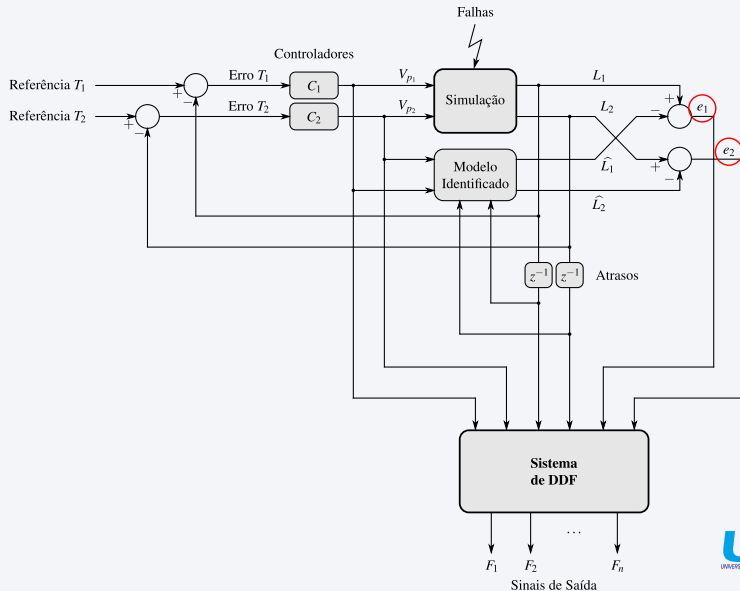
Composição do sistema



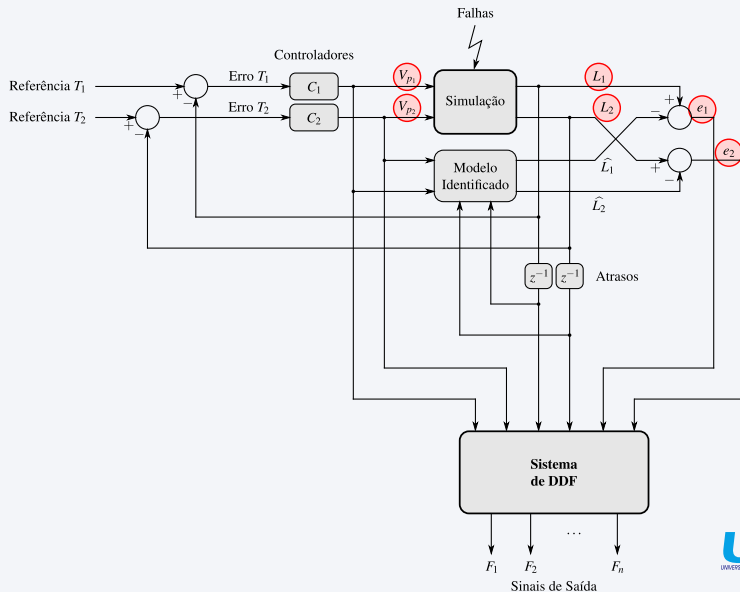
Composição do sistema



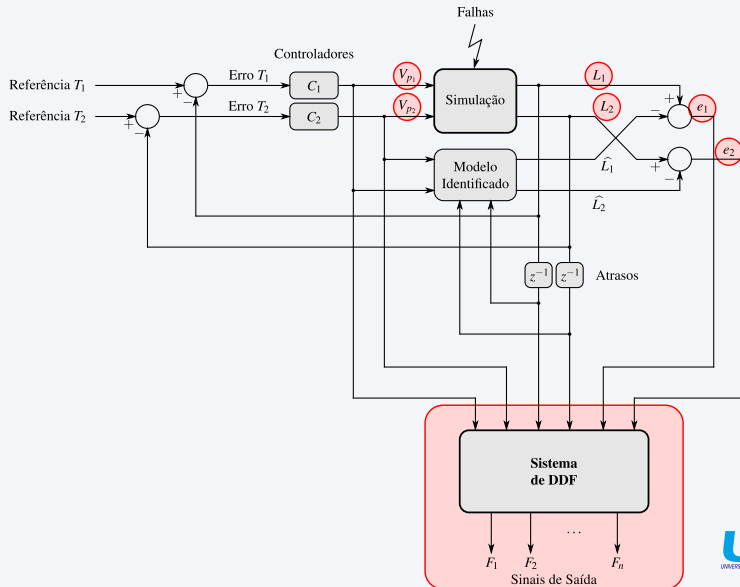
Composição do sistema



Composição do sistema



Composição do sistema

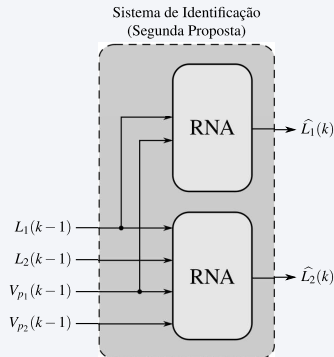



Estruturas neurais – Identificação



Duas propostas de identificação do modelo:

- Identificação global (uma RNA para T_1 e T_2)
- Identificação individual (uma RNA para cada tanque)




Estruturas neurais – Detecção



Duas propostas de detecção:

- RNA única (todas as falhas)
- Conjunto de especialistas (uma RNA para cada falha)

Primeira proposta:

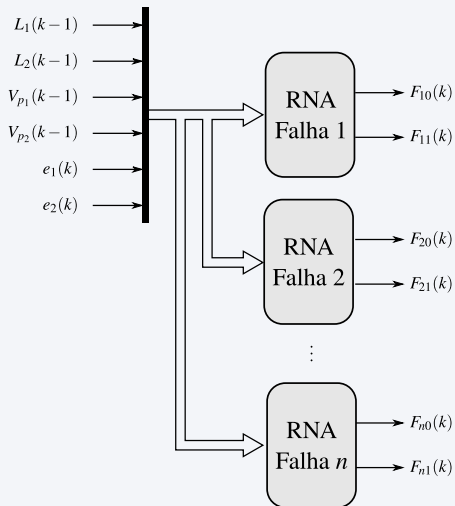


Saída \Rightarrow Palavra binária de n bits

Estruturas neurais – Detecção



Segunda proposta:



Saída \Rightarrow 2 bits

- Sem falha
- Falha T_1
- Falha T_2
- Falha $T_1 + T_2$



1 Introdução

- Introdução da automação na indústria
- Sistemas de supervisão
- Proposta do trabalho

2 RNAs

- Características
- Arquitetura e modelo neural

3 Detecção e diagnóstico de falhas

- Conceitos e terminologias
- Dependabilidade
- Falhas, erros e avarias
- Classificações de falhas
- Detecção e diagnóstico

4 Sistema proposto

- Estudo de caso
- Estrutura de funcionamento e limitações
- Softwares desenvolvidos
- Composição do sistema
- Estruturas neurais

5 Resultados

- Coleta dos dados
- Treinamento e validação das RNAs
- Melhores redes
- Resultados das simulações

6 Conclusões

- Perspectivas

7 Vídeo

Coleta dos dados



Após ter selecionado as falhas e as estruturas neurais:

- Excitação da planta com sinais PRBS dentro de um *range* especificado
 - Referências: 0 a 30 cm
 - Ruído: $\pm 2\%$
 - $K'_m = \pm 20\% K_m$
 - ...
- Testes realizados:
 - Simulação do sistema sem falhas \Rightarrow identificação do modelo
 - Simulação com falhas \Rightarrow propostas de detecção

Treinamento e validação das RNAs



Treinamento:

- Identificação: 10 minutos (6000 amostras)
- Detecção: 20 minutos (12000 amostras)

Número de redes treinadas:

Proposta	Ordem	Neurônios na camada oculta	Número de redes treinadas	Total
Identificação				
1	2	6, 8 e 10	6	54
	3	8, 12 e 16		
	4	10, 16 e 22		
2	2	2/6, 4/8 e 6/10	6	108
	3	4/8, 6/12 e 8/16		
	4	6/10, 8/16 e 10/22		
Detecção				
1	—	—	—	—
2	2	8/12/16	6/falha	702
	3	14/18/22		
	4	20/24/28		
Total geral				864

Melhores redes



RNAs de Identificação:

- 3 validações
- Média dos EMQs em L_1 e L_2
- Critério de seleção $EMQ = EMQ L_1 + EMQ L_2$

Proposta	Ordem	NCO*	Treinamento	EMQ L_1	EMQ L_2	EMQ
1	2	8	2	4,39e-7	3,29e-6	3,73e-6
	3	12	5	1,38e-5	1,46e-5	2,84e-5
	4	22	4	1,40e-6	2,60e-6	4,01e-6
2	2	2 – 6	2	5,06e-6	7,26e-6	1,23e-5
	3	6 – 12	1	5,48e-6	1,81e-7	5,66e-6
	4	10 – 22	3	5,12e-6	9,46e-6	1,45e-5

* Número de neurônios na camada oculta.



RNAs de detecção:

- Seleccionadas de modo semelhante: 3 validações
- Critérios de seleção
 - Número de erros de tipo I e tipo II (falsos positivos/negativos)
 - Porcentagem total de erros sobre as 3 validações

Melhores redes



Falha	Ordem	NCO	Trein.	Acertos	Erros de tipo I	Erros de tipo II	Total de erros
FSeDG	4	28	2	23491,33	203,33	305,33	2,12%
FSeDO	4	28	5	23890,33	8,66	101	0,46%
FSeSR	4	20	3	23317	324,66	358,33	2,84%
FSeQ	4	20	4	23994	0,66	5,33	0,02%
FADG	2	8	3	20710,33	1626,66	1663	13,7%
FADO	4	28	3	23075,33	635,66	289	3,85%
FASR	2	8	6	14153,33	3407	6439,66	41,03%
FAVK	2	8	5	20764,66	1551,33	1684	13,48%
FAQ	4	28	6	23980	2,33	17,66	0,083%
FSiVzT	4	24	1	23774,33	74	151,66	0,94%
FSiVrOS	2	8	3	22465,33	437	1097,66	6,39%
FSiVrGMP	4	20	2	20905,66	1979,66	1114,66	12,89%
FSiEOS	2	12	4	23995,66	1	3,33	0,018%

Melhores redes




Falha	Ordem	NCO	Trein.	Acertos	Erros de tipo I	Erros de tipo II	Total de erros
FSeDG	4	28	2	23491,33	203,33	305,33	2,12%
FSeDO	4	28	5	23890,33	8,66	101	0,46%
FSeSR	4	20	3	23317	324,66	358,33	2,84%
FSeQ	4	20	4	23994	0,66	5,33	0,02%
FADG	2	8	3	20710,33	1626,66	1663	13,7%
FADO	4	28	3	23075,33	635,66	289	3,85%
FASR	2	8	6	14153,33	3407	6439,66	41,03%
FAVK	2	8	5	20764,66	1551,33	1684	13,48%
FAQ	4	28	6	23980	2,33	17,66	0,083%
FSiVzT	4	24	1	23774,33	74	151,66	0,94%
FSiVrOS	2	8	3	22465,33	437	1097,66	6,39%
FSiVrGMP	4	20	2	20905,66	1979,66	1114,66	12,89%
FSiEOS	2	12	4	23995,66	1	3,33	0,018%

Resultados das simulações



Simulação final:

- Utilização das melhores redes de identificação e detecção
- Cada falha \Rightarrow 1 minuto e 45 segundos

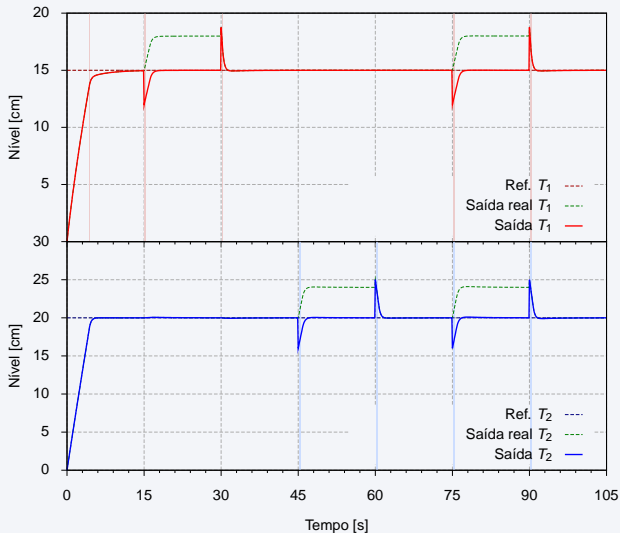


- Valores dos parâmetros das falhas \Rightarrow mantidos fixos dentro do *range* estabelecido para o treinamento

Resultados das simulações



Simulação da FSeDG com o ganho reduzido a 80% do valor original:



Resultados das simulações



Detecção da falha somente no instante de ativação da falha

Compensação do controlador (com erro de 20%) $\Rightarrow 24\text{cm} \equiv 30\text{cm}$


Comportamento semelhante na FSeDO e na FSiVzT

Possibilidade de utilização de *flags* para correção do problema

Resultados das simulações



Simulação da FSeSR com ruído de distribuição uniforme ($\pm 2\%$):



Resultados das simulações



Bons resultados \Rightarrow poucos erros

Todas as demais falhas se comportaram de maneira semelhante
 \Rightarrow facilmente detectadas \Rightarrow Exceções FASR e FSiVrGMP

FASR:

- Resultados T_1 ✓
- Resultados T_2 ✗

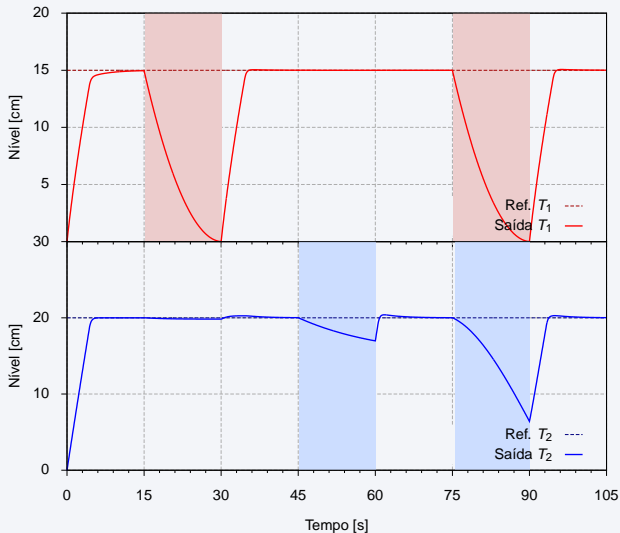
FSiVrGMP:

- Não consegue identificar falha somente em T_1 (intervalo 15-30s)

Resultados das simulações




Simulação da FAQ (Ganho = 0):



Resultados das simulações




Simulação da FASR com ruído de distribuição uniforme ($\pm 2\%$):



Resultados das simulações



Simulação da FSiVrGMP com o ganho reduzido a 90% do valor original:





1 Introdução

- Introdução da automação na indústria
- Sistemas de supervisão
- Proposta do trabalho

2 RNAs

- Características
- Arquitetura e modelo neural

3 Detecção e diagnóstico de falhas

- Conceitos e terminologias
- Dependabilidade
- Falhas, erros e avarias
- Classificações de falhas
- Detecção e diagnóstico

4 Sistema proposto

- Estudo de caso
- Estrutura de funcionamento e limitações
- Softwares desenvolvidos
- Composição do sistema
- Estruturas neurais

5 Resultados

- Coleta dos dados
- Treinamento e validação das RNAs
- Melhores redes
- Resultados das simulações

6 Conclusões

- Perspectivas

7 Vídeo

Conclusões



Proposta do trabalho: fornecer um sistema de DDF para um sistema de tanques acoplados

- Das 13 falhas testadas, 8 foram identificadas com facilidade
- 3 tiveram desempenho satisfatório (correção do problema com *flags*)
- Outros 2 casos o sistema não conseguiu detectar corretamente

Desempenho geral satisfatório: detecção correta de 85% das falhas propostas

Utilização de RNAs (PMC, NNARX) mostrou-se eficiente



Perspectivas de trabalhos futuros:

- Implementação de novos módulos de detecção/diagnóstico:
 - Fuzzy
 - Estatísticos
- Permitir a simulação de novos modelos
 - Utilizando o RK4
 - Integrando o sistema com o Matlab[®]
- Acoplar o sistema a um Sistema de Controle Tolerante a Falhas (SCTF) – Não é o escopo deste trabalho
 - Reconfiguração dos controladores ou mudança das estratégias de controle, permitindo que o sistema continue operando mesmo na presença de falhas



1 Introdução

- Introdução da automação na indústria
- Sistemas de supervisão
- Proposta do trabalho

2 RNAs

- Características
- Arquitetura e modelo neural

3 Detecção e diagnóstico de falhas

- Conceitos e terminologias
- Dependabilidade
- Falhas, erros e avarias
- Classificações de falhas
- Detecção e diagnóstico

4 Sistema proposto

- Estudo de caso
- Estrutura de funcionamento e limitações
- Softwares desenvolvidos
- Composição do sistema
- Estruturas neurais

5 Resultados

- Coleta dos dados
- Treinamento e validação das RNAs
- Melhores redes
- Resultados das simulações

6 Conclusões

- Perspectivas

7 Vídeo



Vídeo do sistema desenvolvido



Dúvidas?